

# Linguagens de Anotação:

## XML - Aplicações e Tecnologias Associadas

# Motivação 1

- Um dia de trabalho = produção de vários documentos
- Muitos têm uma forma estruturada
- Alguns até podem ser representados numa tabela: inventários, preços, ...
- Mas, apenas 10% da informação é guardada em Bases de Dados
- Que fazer com os restantes 90%?

# Os restantes 90%

- Correspondem a textos que circulam dentro das instituições
- Não se lhes pode aplicar uma metodologia relacional
- Haverá alguma maneira de contornar o problema?
- A solução recai sobre a estruturação da informação

# Exemplo: uma carta

Exmo Vice-Reitor

Prof. Dr. José Viriato Eiras Capela

Devido à proximidade do prazo e ao trabalho em que ... venho, por este meio, solicitar-lhe que conceda mais 30 dias para a submissão final da tese de mestrado a dois dos meus orientandos: Joel Vicente (Mestrado em Informática) e Luis Miguel Alves Domingues (Mestrado em Informática).

...

Com os melhores cumprimentos

Universidade do Minho, Braga,  
21 de Setembro de 2005

José Carlos Leite Ramalho  
(Professor Auxiliar)

# Motivação 2

- Publicação Electrónica
  - Proliferação das TICs = proliferação de formatos
  - Explosão da Web veio agravar ainda mais
  - Questão: Como conseguir produzir documentos num formato neutro a partir do qual seja possível gerar todos os formatos necessários para distribuição?

**Será possível atingir a interoperabilidade sem um denominador comum?**

# Documentação Estruturada

- Valor de um documento = facilidade na localização, no consumo, na validação e na reutilização
- Um documento estruturado tem as seguintes vantagens:
  - Acesso
  - Validação
  - Reutilização
  - Normalização

# Anotação

- “Markup” = anotação, codificação, etiquetagem
- A anotação de um texto é um meio de tornar explícita uma interpretação desse texto
- Exemplo:
  - “Está a chover.”
  - “Está a chover?”

# Objectivos da Anotação

1. Dividir o documento em componentes
  - Dá organização lógica (explicitamente)
  - Dá indicações para o processamento (implicitamente)
2. Associar semântica
  - Dá interpretação (implicitamente)
  - Dá indicações para a formatação (explicitamente)



# Fases da Anotação

1. Análise da estrutura da informação (dos documentos que se pretende tratar).
2. Definição da formatação/transformação desejada para cada elemento estrutural.
3. Inserção das anotações no documento.

# Pausa para pensar

- Exercício: anotar o poema
- Exercício: definir as anotações para a agenda
- Exercício: anotar um relatório

# Exercício: o poema

"Soneto Já Antigo"  
(Álvaro de Campos)

Olha, Daisy: quando eu morrer tu hás-de  
dizer aos meus amigos aí de Londres,  
embora não o sintas, que tu escondes  
a grande dor da minha morte. Irás de

Londres p'ra Iorque, onde nasceste (dizes  
que eu nada que tu digas acredito),  
contar áquele pobre rapazito  
que me deu horas tão felizes,

embora não o saibas, que morri...  
Mesmo ele, a quem eu tanto julguei amar,  
nada se importará... Depois vai dar

a notícia a essa estranha Cecily  
que acreditava que eu seria grande...  
Raios partam a vida e quem lá ande!

(1922)

**Poema:** título, autor, corpo, data

**Corpo:** quadra, quadra, terceto,  
terceto.

**Quadra:** verso, verso, verso,  
verso

**Terceto:** verso, verso, verso

**Verso:** (texto | nome)+

**Nome:** texto

# Anotação Descritiva

**<carta>**

**<destinatario>** Exmo Vice-Reitor

Prof. Dr. José Viriato Eiras Capela **</destinatario>**

**<corpo>**

Devido à proximidade do prazo e ao trabalho em que ... venho, por este meio, solicitar-lhe que conceda mais 30 dias para a submissão final da tese de mestrado a dois dos meus orientandos: Joel Vicente (Mestrado em Informática) e Luis Miguel Alves Domingues (Mestrado em Informática).  
... **</corpo>**

**<fecho>** Com os melhores cumprimentos

Universidade do Minho, Braga,

21 de Setembro de 2005

José Carlos Leite Ramalho

(Professor Auxiliar) **</fecho>**

**</carta>**

**Utiliza etiquetas para apenas classificar as componentes do documento.**

# Linguagem de Anotação

- Especifica como distinguir a anotação do texto
- Especifica **que** anotações são **necessárias** e **quais** são **permitidas**
- Especifica **onde** as anotações são **neces-sárias** e **onde** são **permitidas**
- Define o significado da anotação

O XML tem estas características todas ... excepto a última

# Perspectivas de Anotação

1. Anotação orientada ao formato
  2. Anotação orientada à estrutura
  3. Anotação orientada ao conteúdo
- Objectivo: Anotação Equilibrada

# Anotação orientada ao formato

**<quadra>**

Olha, **<realçado>** Daisy **</realçado>** : quando eu morrer tu hás-de dizer aos meus amigos aí de **<realçado>** Londres **</realçado>**, embora não o sintas, que tu escondes a grande dor da minha morte. Irás de **</quadra>**

# Anotação orientada à estrutura

```
<SEC>Isto é uma secção de nível 1.  
<SEC>Isto é uma secção de nível 2.</SEC> </SEC>  
<P>Isto é um parágrafo do nível de topo.</P>  
<LISTA>  
  <ITEM>Isto é um item de uma lista de nível 1.  
  <LISTA><ITEM>Isto é um item de uma lista de  
    nível 2.</ITEM>  
</LISTA></ITEM></LISTA>
```

```
<SEC1>Isto é uma secção de nível 1.</SEC1>  
<SEC2>Isto é uma secção de nível 2.</SEC2>  
<P0>Isto é um parágrafo do nível de topo.</P0>  
<LISTA1><ITEM>Isto é um item de uma lista de nível 1.</ITEM></LISTA1>  
<LISTA2><ITEM>Isto é um item de uma lista de nível 2.</ITEM></LISTA2>
```



# Anotação orientada ao conteúdo

```
...  
<quadra>  
  <verso>Olha, <nome>Daisy</nome>: quando eu morrer  
    tu hás-de</verso>  
  <verso>dizer aos meus amigos aí de  
    <lugar>Londres</lugar>,</verso>  
  <verso>embora não o sintas, que tu escondes</verso>  
  <verso>a grande dor da minha morte. Irás de</verso>  
</quadra>  
...
```

# Anotação Equilibrada

- Exemplo: DocBook
  - Formato: EMPH, TABLE,...
  - Estrutura: SECT1, SECT2, SECT3, ...
    - Conteúdo: NAME, AUTHOR, PUBDATE, COMMAND, ...

# **Documentos XML bem formados**

# Um documento XML

- Conteúdo = Dados + Anotações
- Dados = blocos de texto
- Anotações:
  - marcas de início de elementos
  - marcas de fim de elementos
  - marcas de elementos vazios
  - referências a entidades
  - comentários
  - limitadores de secções especiais de texto
  - declarações de tipo de documento
  - instruções de processamento

# O exemplo tradicional

```
<?xml version="1.0" encoding="UTF-8"?>  
  
  <doc>  
  
    Hello World!!!  
  
  </doc>
```

# A declaração XML

- Anotação especial que deve iniciar todos os documentos XML

```
<?xml
```

```
  version="1.0"
```

```
  standalone="yes"
```

```
  encoding="UTF-8"
```

**version** - obrigatório, valores possíveis: 1.0

**standalone** - opcional, valores possíveis: yes, no;

**encoding** - opcional, para o português o valor deverá ser: ISO-8859-1

# Comentários

- Podem aparecer em qualquer ponto dum documento XML.
- Começam pela marca: <!--
- e terminam com a marca: -->.

```
<?xml version="1.0" encoding="ISO-8859-1"?>
```

```
<!--Isto é um comentário no início-->
```

```
<doc>
```

```
    Olá Mundo!!!
```

```
</doc>
```

# Instruções de Processamento

- As instruções de processamento são uma reminiscência da anotação procedimental
- Uma instrução de processamento não faz parte do conteúdo do documento.
- É uma indicação directa de que algo deve ser executado naquele ponto.
- Uma instrução de processamento começa por: `<?id-processor`
- e termina por: `?>`
- Exemplo: a declaração XML



# Instruções de Processamento 2

```
<?xml version="1.0" encoding="ISO-8859-1"?>
<agenda>
  <?html action="hr"?>
    <entrada id="e1" tipo="pessoa">
      <nome>José Carlos Ramalho</nome>
      <email>jcr@di.uminho.pt</email>
      <telefone>253 604479</telefone>
    </entrada>
  <?html action="hr"?>
  ...
</agenda>
```

# Elementos

- Blocos lógicos em que um documento pode ser decomposto
- Exemplo:
  - Vais ver o espectáculo a <lugar>Braga</lugar>?
- Uma anotação de início começa por < e termina por > ,
- e uma anotação de fim começa por </ e termina por > .
- Uma anotação contém o nome do elemento que inicia ou que termina, respectivamente.

# Caracteres reservados

- No conteúdo dum elemento, nunca deverão ser usados os caracteres '<' e '>' pois são os caracteres que limitam as anotações.
- Em lugar deles devem-se usar, respectivamente, as entidades do tipo carácter '&lt;' e '&gt;'.
- Qualquer processador ou editor de XML fará a substituição automática daquelas entidades pelos caracteres correspondentes.

# Tipos de Conteúdo

- elemento com conteúdo textual
  - `<lugar>Braga</lugar>`
  - `<INGREDIENTE>Meia dúzia de ovos</INGREDIENTE>`
  - `<data>(1922)</data>`
- elemento com conteúdo misto
  - `<verso>Olha, <nome>Daisy</nome>: quando ...</verso>`  
`<p>Vais ver o espectáculo a <lugar>Braga</lugar><?</p>`

# Tipos de Conteúdo (2)

- elementos com conteúdo vazio: são normalmente utilizados pelo seu significado posicional - referências, pontos de inserção de imagens, ...
  - **Como será discutido num capítulo mais à frente (<ref id="cap5"/>) ...**
  - São representados por uma única anotação que é iniciada por '<' e termina em '/>', que é a forma abreviada de escrever “<elem-ident></elem-ident>”.

# Atributos

- Um elemento pode ter um ou mais atributos que, por sua vez, podem ser opcionais ou obrigatórios.
- Visam qualificar o elemento a que estão associados.
- Não há limite para o número de atributos que podem estar associados a um elemento.
- Aparecem sempre na anotação que marca o início dum elemento, uma vez que vão qualificar o conteúdo que se segue.

# Atributos (2)

- Um atributo é definido por um par constituído por um nome e um valor:
  - o nome e o valor devem estar separados pelo sinal '=' e
  - o valor deverá estar colocado dentro de aspas simples ou duplas.
  - Exemplo:  
`<ref destino="exemplo5"/>`  
`<imagem path="figs/img3.gif"/>`

# Elemento versus Atributo

- Não existe uma fronteira entre os dois e muitas vezes a escolha não é simples.

## Informação nos elementos

```
<agenda>
  <entrada id="e1" tipo="pessoa">
    <nome>José Carlos Ramalho</nome>
    <email>jcr@di.uminho.pt</email>
    <telefone>253 604479</telefone>
```

```
</entrada>
```

```
...
```

```
</agenda>
```

## Informação nos atributos

```
<agenda>
  <entrada id="e1" tipo="pessoa" nome="José Carlos Ramalho"
    email="jcr@di.uminho.pt" telefone="253 604479"/>
  ...
</agenda>
```



# Regras de bem-formação

- Um documento XML deve ter sempre uma declaração XML no início
- O documento deve incluir um ou mais elementos
- Todos os elementos têm anotações de início e fecho (excepto os vazios)
- Os elementos deverão estar aninhados correctamente
- Os valores de atributos têm de estar dentro de aspas

# Documento XML exemplo

```
<?xml version="1.0" encoding="UTF-8"?>
<tree>
  <node id="peter">
    <name>Peter</name>
    <birth>1991</birth>
    <mother refid="mary"/>
    <father refid="joseph"/>
  </node>

  <node id="mary">
    <name>Mary</name>
    <birth>1956</birth>
  </node>
```

```
<node id="joseph">
  <name>Joseph</name>
  <birth>1955</birth>
  <mother refid="margaret"/>
  <father refid="luigi"/>
</node>

<node id="margaret">
  <name>Margaret</name>
  <birth>1923</birth>
</node>
<node id="luigi">
  <name>Luigi</name>
  <birth>1920</birth>
</node>
</tree>
```

# Documentos XML válidos

Respeitam um conjunto de regras:

- DTD
- XML Schema
- Relax NG

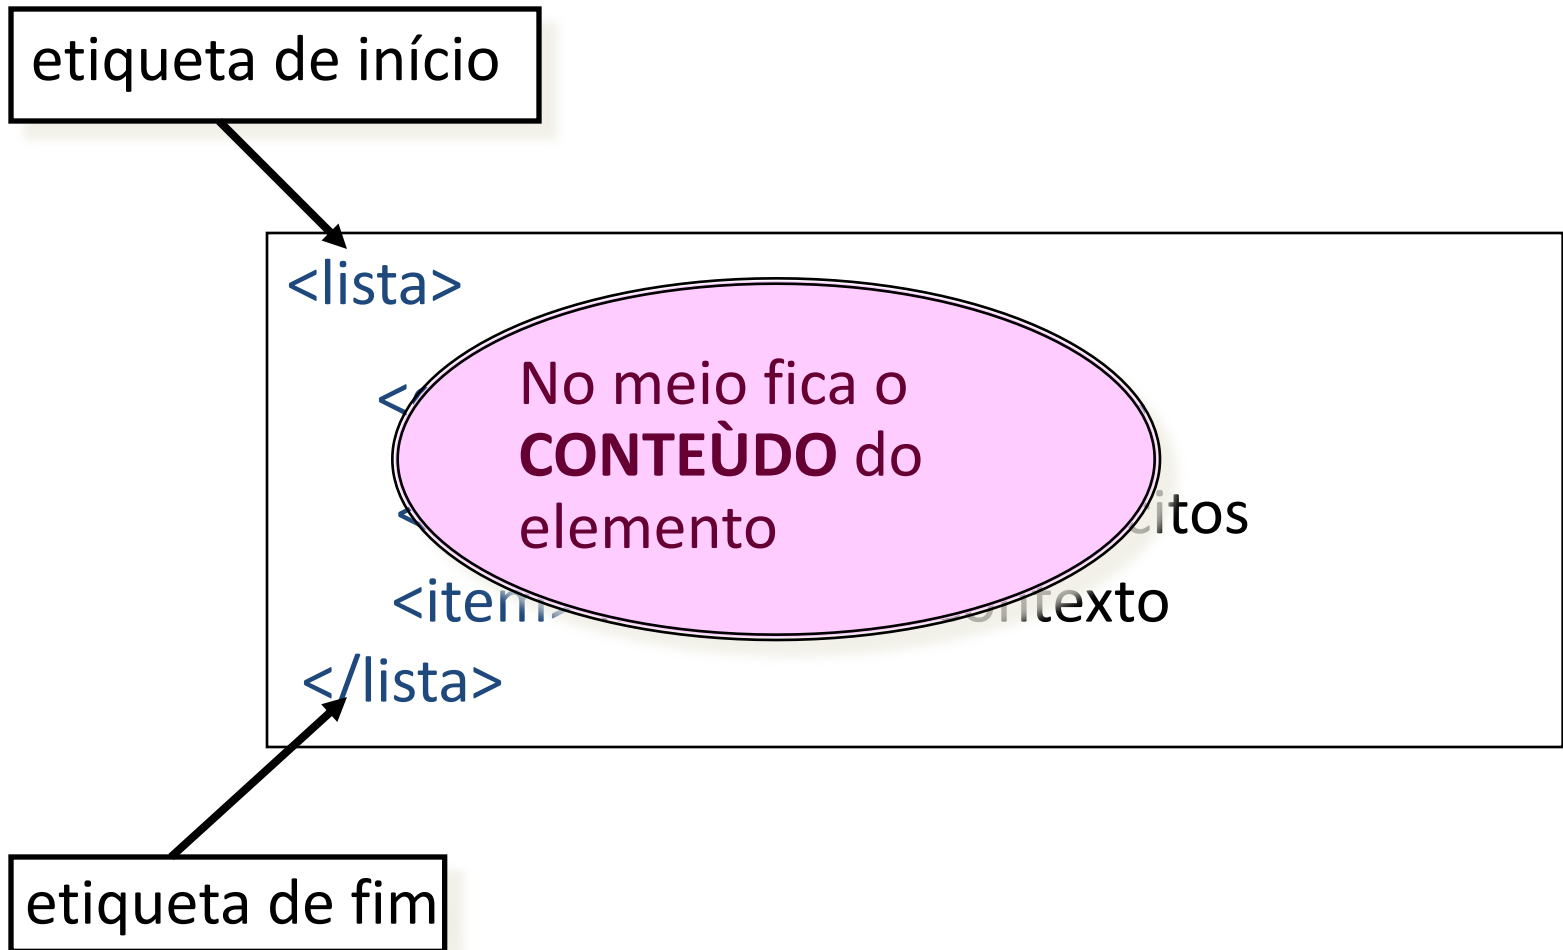
# DTDs

# XML: exemplo

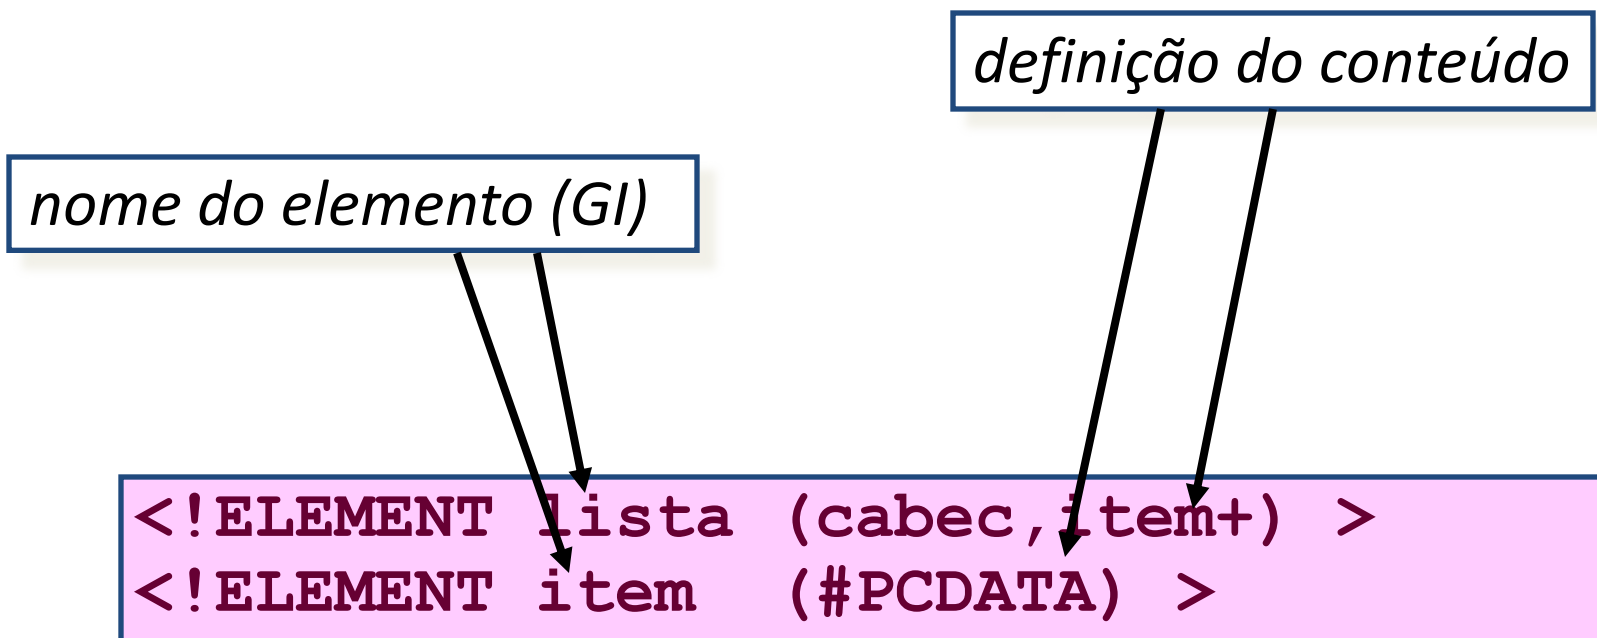
```
<lista>  
  <cabec>Os delimitadores podem ser: </cabec>  
  <item> explícitos </item>  
  <item> inferidos do contexto </item>  
</lista>
```

*O elemento do tipo **LISTA** é formado por um elemento **CABEC**, seguido por dois elementos do tipo **ITEM**.*

# Ocorrência de um elemento



# Definição de um elemento



# Definição do CONTEÚDO

- outros elementos especificados
- ANY (qq elemento especificado)
- EMPTY (nada, vazio)
- #PCDATA (texto)
- uma mistura de elementos com #PCDATA



# Expressão de Conteúdo: sintaxe

- sequência

$a, b$     *a seguido de b*

$a|b$     *a ou b mas não ambos*

- ocorrência

$a$     *um e apenas um*

$a?$     *opcionalmente um (0 ou 1)*

$a^*$     *zero ou mais*

$a^+$     *um ou mais*

# Exemplo: o poema

Poema: título, autor, corpo, data

Corpo: quadra, quadra, terno,  
terno.

Quadra: verso, verso, verso,  
verso

Terno: verso, verso, verso

Verso: (texto | nome)+

Nome: texto

```
<!ELEMENT poema (título,autor,corpo,data) >  
<!ELEMENT corpo (quadra,quadra,terno,terno) >  
<!ELEMENT quadra (verso,verso,verso,verso) >  
<!ELEMENT terno (verso,verso,verso) >  
<!ELEMENT verso (#PCDATA |nome)* >
```

# Exercício (pausa)

**Especificar o DTD para a Agenda**

# Exercício (pausa)

- Visualizar o cartão e especificar um DTD para cartões;
- Visualizar a declaração e especificar um DTD para documentos deste tipo;

# Exercício: o cartão



José Carlos Ramalho  
jcr@keep.pt

Rua Rosalvo de Almeida, nº 5, 4710-429 Braga, Portugal

**T** (+351) 253066735   **F** (+351) 253604471   **E** info@keep.pt   **W** www.keep.pt

# Exercício: a declaração

## Declaração

Declara-se para os devidos efeitos que a empresa KEEP SOLUTIONS, LDA portadora do contribuinte n.º 508496870, possui Contabilidade Organizada segundo o Sistema de Normalização Contabilístico.

Mais se informa que a empresa:

1. Dispõe de um sistema que atesta, nos casos dos custos comuns, encontra-se identificada, para cada candidatura, a chave de imputação e os seus pressupostos;
2. Dispõe de um sistema que permite a individualização dos custos associados à candidatura, de acordo com a estrutura de custos aplicável.
3. Atesta a regularidade das operações contabilísticas nos pedidos de reembolso e encerramento de contas.

O técnico oficial de contas,

*Christiane Guimaraes*